

Tugas 2: Machine Learning – Clustering (DBSCAN)

Muhammad Zaidan Ramdhan - 0110222040

Teknik Informatika, STT Terpadu Nurul Fikri, Depok

*E-mail: muha22040ti@student.nurulfikri.ac.id

Laporan ini bertujuan untuk menerapkan teknik *unsupervised learning* menggunakan algoritma clustering berbasis densitas pada dataset gempa bumi di Indonesia. Fokus utama analisis adalah pemanfaatan koordinat GPS (latitude dan longitude) untuk mengidentifikasi pola spasial, densitas kejadian, serta wilayah yang menjadi pusat aktivitas seismik.

Pada tahap awal, dilakukan proses preprocessing data berupa penghapusan nilai hilang (*missing values*), duplikasi data, serta normalisasi fitur numerik agar memperbaiki performa algoritma clustering. Selanjutnya dilakukan analisis eksploratif (EDA) yang mencakup visualisasi spasial berupa scatter plot dan heatmap. Hasil visualisasi menunjukkan bahwa kejadian gempa memiliki persebaran yang tidak acak, melainkan terkonsentrasi pada jalur subduksi yang membentang dari Sumatera, selatan Jawa, Bali, Nusa Tenggara, hingga Maluku, Sulawesi, dan Papua.

Evaluasi model dilakukan menggunakan Silhouette Score, yang hanya dihitung untuk data yang berhasil membentuk cluster (bukan noise). Nilai silhouette score yang diperoleh menunjukkan bahwa model dapat mengelompokkan data secara wajar dan konsisten sesuai struktur alamiah dataset, meskipun variasi densitas antar wilayah cukup tinggi. Hasil analisis menunjukkan bahwa metode clustering berbasis densitas seperti HDBSCAN dapat memberikan insight penting terkait zona rawan gempa di Indonesia. Visualisasi dalam bentuk peta heatmap dan peta cluster interaktif memperkuat kesimpulan bahwa pola kejadian gempa mengikuti struktur tektonik aktif Indonesia yang merupakan bagian dari Ring of Fire.

1. Tugas mandiri – Latihan

```
1. Melakukan mounting G-Drive

from google.colab import drive
drive.mount("/content/gdrive")

Mounted at /content/gdrive
```

Gambar 1. 1

Pada *Gambar 1.1* di atas, merupakan sebuah code untuk mounted atau menghubungkan google colab dengan google drive.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import silhouette_score
import folium
from folium.plugins import HeatMap
import hdbscan
```

Gambar 1. 2

Pada *Gambar 1.2* di atas, merupakan sebuah code untuk import beberapa library yang akan kita gunakan.

```
df = pd.read_csv(path + '/praktikum_mandiri/data/katalog_gempa.csv')
df
```

	tgl	ot	lat	lon	depth	mag	remark	strike1	dip1	rake1	strike2	dip2	rake2
0	2008/11/01	21:02:43.058	-9.18	119.06	10	4.9	Sumba Region - Indonesia	NaN	NaN	NaN	NaN	NaN	NaN
1	2008/11/01	20:58:50.248	-6.55	129.64	10	4.6	Banda Sea	NaN	NaN	NaN	NaN	NaN	NaN
2	2008/11/01	17:43:12.941	-7.01	106.63	121	3.7	Java - Indonesia	NaN	NaN	NaN	NaN	NaN	NaN
3	2008/11/01	16:24:14.755	-3.30	127.85	10	3.2	Seram - Indonesia	NaN	NaN	NaN	NaN	NaN	NaN
4	2008/11/01	16:20:37.327	-6.41	129.54	70	4.3	Banda Sea	NaN	NaN	NaN	NaN	NaN	NaN
...	...	...	...	...	...	...	...	...	...	...	...	...	...
92882	2023/01/26	02:25:09.288	3.24	127.18	10	4.0	Talaud Islands - Indonesia	NaN	NaN	NaN	NaN	NaN	NaN
92883	2023/01/26	02:15:03.893	2.70	127.10	10	3.9	Northern Molucca Sea	NaN	NaN	NaN	NaN	NaN	NaN
92884	2023/01/26	01:57:08.885	-7.83	121.07	10	3.8	Flores Sea	NaN	NaN	NaN	NaN	NaN	NaN
92885	2023/01/26	01:46:21.009	3.00	127.16	10	4.1	Northern Molucca Sea	NaN	NaN	NaN	NaN	NaN	NaN
92886	2023/01/26	00:00:35.181	-8.87	118.95	10	2.4	Sumbawa Region - Indonesia	NaN	NaN	NaN	NaN	NaN	NaN

92887 rows × 13 columns

Gambar 1. 3

Pada *Gambar 1.3* di atas, merupakan code untuk menampilkan dataset yang digunakan untuk yaitu katalog_gempa.csv.

```
df = df.drop(['ot', 'strike1', 'dip1', 'rake1', 'strike2', 'dip2', 'rake2'], axis=1)

df['tgl'] = pd.to_datetime(df['tgl'])
```

Gambar 1. 4

Pada *Gambar 1.4* di atas, merupakan sebuah code untuk membuang kolom-kolom yang tidak digunakan untuk dilakukan DBSCAN. Pada kolom tgl dilakukan sebuah formating menggunakan datetime.

```
df.isnull().sum()

0
tgl    0
lat    0
lon    0
depth  0
mag    0
remark 0
dtype: int64
```

Gambar 1. 5

Pada *Gambar 1.5* di atas, merupakan sebuah code untuk mengecek missing value pada kolom yang telah kita pilih.

```
df
```

	tgl	lat	lon	depth	mag	remark
0	2008-11-01	-9.18	119.06	10	4.9	Sumba Region - Indonesia
1	2008-11-01	-6.55	129.64	10	4.6	Banda Sea
2	2008-11-01	-7.01	106.63	121	3.7	Java - Indonesia
3	2008-11-01	-3.30	127.85	10	3.2	Seram - Indonesia
4	2008-11-01	-6.41	129.54	70	4.3	Banda Sea
...	...	...	...	...	...	...
92882	2023-01-26	3.24	127.18	10	4.0	Talaud Islands - Indonesia
92883	2023-01-26	2.70	127.10	10	3.9	Northern Molucca Sea
92884	2023-01-26	-7.83	121.07	10	3.8	Flores Sea
92885	2023-01-26	3.00	127.16	10	4.1	Northern Molucca Sea
92886	2023-01-26	-8.87	118.95	10	2.4	Sumbawa Region - Indonesia


92887 rows × 6 columns

Gambar 1. 6

Pada *Gambar 1.6* di atas, merupakan sebuah code untuk menampilkan data setelah kita melakukan pemilihan kolom yang akan kita gunakan.

```
# =====
# 4 EXPLORATORY DATA ANALYSIS (EDA)
# =====

# Scatter plot persebaran gempa
plt.figure(figsize=(6,6))
plt.scatter(df['lon'], df['lat'], s=5)
plt.xlabel("Longitude")
plt.ylabel("Latitude")
plt.title("Sebaran Lokasi Gempa di Indonesia")
plt.show()
```



Gambar 1.7

Pada *Gambar 1.7* di atas, merupakan sebuah code untuk menampilkan sebaran lokasi gempa yang ada di Indonesia.

```
# =====  
# 5 NORMALISASI DATA  
# =====  
  
# Select only numerical columns for scaling  
df_numerical = df[['lat', 'lon', 'depth', 'mag']]  
  
scaler = StandardScaler()  
data_scaled = scaler.fit_transform(df_numerical)  
  
data_scaled[:5]  
  
array([[ -1.3262929 , -0.00920386, -0.50819522,  1.56732953],  
       [ -0.72232838,  0.96742863, -0.50819522,  1.20763358],  
       [ -0.82796476, -1.15660857,  0.93785807,  0.12854573],  
       [  0.0240156 ,  0.80219496, -0.50819522, -0.47094752],  
       [ -0.69017818,  0.9581977 ,  0.27345521,  0.84793763]])
```

Gambar 1.8

Pada *Gambar 1.8* di atas, merupakan sebuah code untuk melakukan scaling pada kolom yang kita gunakan.

```
# =====
# 6 HDBSCAN CLUSTERING
# =====
clusterer = hdbscan.HDBSCAN(min_cluster_size=50)
labels = clusterer.fit_predict(data_scaled)

df['cluster'] = labels
df.head()
```

/usr/local/lib/python3.12/dist-packages/sklearn/utils/deprecation.py:151: FutureWarning:
warnings.warn(
/usr/local/lib/python3.12/dist-packages/sklearn/utils/deprecation.py:151: FutureWarning:
warnings.warn(

	tgl	lat	lon	depth	mag	remark	cluster
0	2008-11-01	-9.18	119.06	10	4.9	Sumba Region - Indonesia	-1
1	2008-11-01	-6.55	129.64	10	4.6	Banda Sea	-1
2	2008-11-01	-7.01	106.63	121	3.7	Java - Indonesia	-1
3	2008-11-01	-3.30	127.85	10	3.2	Seram - Indonesia	29
4	2008-11-01	-6.41	129.54	70	4.3	Banda Sea	-1

Gambar 1.9

Pada *Gambar 1.9* di atas, merupakan sebuah code untuk membuat clustering menggunakan data yang telah kita scaling tadi.

```
# Jumlah cluster dan noise (-1)
print(df['cluster'].value_counts())
```

cluster	count
-1	63456
13	3914
36	3025
6	2343
11	1910
...	
97	55
52	52
90	51
53	51
40	50

Name: count, Length: 108, dtype: int64

Gambar 1.10

Pada *Gambar 1.10* di atas, merupakan sebuah code untuk mengecek jumlah cluster dan noise.

```
total_gempa = df.shape[0]
jumlah_gempa_per_hari = df.groupby(df['tgl'].dt.date).size()

rata_rata_gempa_per_hari = jumlah_gempa_per_hari.mean()

print('Total jumlah gempa:', total_gempa)
print('Rata-rata jumlah gempa per hari:', rata_rata_gempa_per_hari)
```

Total jumlah gempa: 92887
Rata-rata jumlah gempa per hari: 21.053263825929285

Gambar 1.11

Pada *Gambar 1.11* di atas, code untuk menampilkan total jumlah gempa dan rata-rata gempa per hari.


```

# Mencari nilai min dan max dari 'mag'
min_mag = df['mag'].min()
max_mag = df['mag'].max()
print ('magnitudo terkecil:', min_mag)
print ('magnitudo terbesar:', max_mag)

# Keterangan gempa berdasarkan magnitudo
bins = [float('-inf'), 3.0, 4.0, float('inf')] # Defining bin edges
labels = ['Kecil', 'Sedang', 'Kuat'] # Labels for the groups
df['keterangan'] = pd.cut(df['mag'], bins=bins, labels=labels, right=False) # Group by mag
print(df[['tgl', 'mag', 'keterangan']])

magnitudo terkecil: 1.0
magnitudo terbesar: 7.9
      tgl  mag keterangan
0  2008-11-01  4.9      Kuat
1  2008-11-01  4.6      Kuat
2  2008-11-01  3.7    Sedang
3  2008-11-01  3.2    Sedang
4  2008-11-01  4.3      Kuat
...      ...      ...
92882 2023-01-26  4.0      Kuat
92883 2023-01-26  3.9    Sedang
92884 2023-01-26  3.8    Sedang
92885 2023-01-26  4.1      Kuat
92886 2023-01-26  2.4    Kecil

[92887 rows x 3 columns]

```

Gambar 1.12

Pada Gambar 1.12 di atas, code untuk menentukan keterangan magnitudo atau kekuatan gempa dari yang terkecil dan terkuat di indonesia.



Gambar 1.13

Pada *Gambar 1.13* di atas, merupakan code untuk melakukan visualisasi dari keterangan kekuatan gempa dari yang terkecil sampai terkuat yang ada di Indonesia.


```
# =====
# 7 SILHOUETTE SCORE (Hanya untuk data bukan noise)
# =====
valid = df[df.cluster != -1]

if len(valid['cluster'].unique()) > 1:
    score = silhouette_score(valid[['lat','lon','depth','mag']], valid['cluster'])
    print("Silhouette Score:", score)
else:
    print("Silhouette score tidak bisa dihitung (cluster hanya 1 atau noise terlalu banyak)")

Silhouette Score: 0.06435883168865836
```


Gambar 1.14

Pada Gambar 1.14 di atas, merupakan code untuk membuat silhouette score pada data clustering.




Gambar 1.15

Pada *Gambar 1.15* di atas, merupakan code untuk membuat visualisasi distribusi silhouette score per titik.



Gambar 1.16

Pada *Gambar 1.16* di atas, merupakan code untuk membuat penyebaran gempa dengan clustering menggunakan peta (folium).



Gambar 1.17

Pada *Gambar 1.17* di atas, merupakan sebuah code untuk membuat visualisasi dengan Heatmap distribusi densitas gempa berdasarkan koordinat GPS. Zona dengan intensitas warna paling cerah (kuning–hijau–putih) menunjukkan area dengan konsentrasi kejadian gempa tertinggi, sedangkan daerah biru menunjukkan gempa lebih jarang, tetapi masih terjadi.

Link github praktikum:

https://github.com/MuhZaidanRamdhan/machine-learning/blob/main/pertemuan11/praktikum_11/notebooks/praktikum_11.ipynb

Link github tugas:

https://github.com/MuhZaidanRamdhan/machine-learning/blob/main/pertemuan11/praktikum_mandiri/notebooks/latihan_11.ipynb