

Tugas 2: Machine Learning – PCA

Muhammad Zaidan Ramdhan - 0110222040

Teknik Informatika, STT Terpadu Nurul Fikri, Depok

*E-mail: muha22040ti@student.nurulfikri.ac.id

Laporan ini bertujuan untuk menerapkan teknik Principal Component Analysis (PCA) sebagai metode reduksi dimensi pada dataset medis *Breast Cancer Wisconsin* yang memiliki jumlah fitur cukup tinggi. Dataset ini terdiri dari 30 fitur numerik hasil pengukuran karakteristik sel kanker, sehingga diperlukan metode untuk menyederhanakan data tanpa menghilangkan informasi penting. PCA digunakan untuk merangkum variasi data ke dalam sejumlah komponen utama yang lebih representatif.

Pada tahap preprocessing, dilakukan penghapusan atribut yang tidak relevan serta transformasi label diagnosis ke dalam bentuk numerik. Selanjutnya, seluruh fitur dinormalisasi menggunakan standarisasi agar memiliki skala yang seragam sebelum diterapkan PCA. Hasil analisis *explained variance* menunjukkan bahwa sebagian besar informasi data dapat dipertahankan hanya dengan beberapa komponen utama, di mana dua komponen utama mampu menjelaskan lebih dari 60% total variansi data.

Visualisasi hasil PCA menunjukkan adanya pemisahan yang cukup jelas antara kelas Benign dan Malignant, meskipun PCA merupakan metode *unsupervised learning*. Hal ini menunjukkan bahwa PCA efektif dalam menangkap struktur utama data dan sangat sesuai digunakan sebagai tahap preprocessing sebelum proses klasifikasi pada dataset medis berdimensi tinggi.

1. Tugas mandiri – Latihan

```
1. Melakukan mounting G-Drive

from google.colab import drive
drive.mount("/content/gdrive")

Mounted at /content/gdrive
```

Gambar 1. 1

Pada *Gambar 1.1* di atas, merupakan sebuah code untuk mounted atau menghubungkan google colab dengan google drive.

```
import pandas as pd
import numpy as np
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt
```

Gambar 1. 2

Pada *Gambar 1.2* di atas, merupakan sebuah code untuk import beberapa library yang akan kita gunakan.

```
df = pd.read_csv(path + '/praktikum_mandiri/data/data.csv')
df
```

	id	diagnosis	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness
0	842302	M	17.99	10.38	122.80	1001.0	0.11840	0.3
1	842517	M	20.57	17.77	132.90	1326.0	0.08474	0.0
2	84300903	M	19.69	21.25	130.00	1203.0	0.10960	0.0
3	84348301	M	11.42	20.38	77.58	386.1	0.14250	0.0
4	84358402	M	20.29	14.34	135.10	1297.0	0.10030	0.0
...	...	...	...	...	...	...	...	...
564	926424	M	21.56	22.39	142.00	1479.0	0.11100	0.0
565	926682	M	20.13	28.25	131.20	1261.0	0.09780	0.0
566	926954	M	16.60	28.08	108.30	858.1	0.08455	0.0
567	927241	M	20.60	29.33	140.10	1265.0	0.11780	0.0
568	92751	B	7.76	24.54	47.92	181.0	0.05263	0.0

569 rows x 33 columns

Gambar 1. 3

Pada *Gambar 1.3* di atas, merupakan code untuk menampilkan dataset yang digunakan untuk yaitu katalog_gempa.csv.

```
df = df.drop(columns=['id', 'Unnamed: 32'])
```

Gambar 1. 4

Penjelasan:

1. Kolom `id` tidak memiliki pengaruh terhadap analisis
2. Kolom `Unnamed: 32` merupakan kolom kosong

Kedua kolom tersebut dihapus agar tidak mempengaruhi proses PCA.

```
df['diagnosis'] = df['diagnosis'].map({'M': 1, 'B': 0})
```

Gambar 1. 5

Penjelasan:

Kolom `diagnosis` bertipe kategorikal sehingga perlu diubah ke bentuk numerik:

M (Malignant) → 1

B (Benign) → 0

```
X = df.drop('diagnosis', axis=1)  
y = df['diagnosis']
```

Gambar 1. 6

Penjelasan:

X berisi seluruh fitur numerik (30 fitur)

y berisi label diagnosis

Pemisahan ini diperlukan agar PCA hanya diterapkan pada fitur, bukan label.

```
scaler = StandardScaler()  
X_scaled = scaler.fit_transform(X)
```

Gambar 1.7

Penjelasan:

Standardisasi dilakukan agar:

Setiap fitur memiliki mean = 0 dan standar deviasi = 1

PCA tidak bias terhadap fitur dengan skala besar

Tahapan ini wajib sebelum menerapkan PCA.

```
pca = PCA()  
X_pca = pca.fit_transform(X_scaled)
```

Gambar 1.8

Penjelasan:

PCA diterapkan tanpa menentukan jumlah komponen untuk:

Mengetahui kontribusi variance dari setiap komponen utama


Menentukan jumlah komponen optimal

```
explained_variance = pca.explained_variance_ratio_
```

Gambar 1.9

Penjelasan:

Variabel ini menunjukkan persentase informasi (variance) yang dijelaskan oleh setiap principal component.



Gambar 1.10

Penjelasan:

Grafik ini digunakan untuk:

1. Menentukan jumlah komponen minimum
2. Mempertahankan informasi $\geq 90\%$

```
pca_2 = PCA(n_components=2)
X_pca_2 = pca_2.fit_transform(X_scaled)
```

Gambar 1.11

Penjelasan:

PCA dengan 2 komponen digunakan untuk:

1. Visualisasi data dalam 2 dimensi
2. Memahami pola pemisahan antar kelas

```
df_pca = pd.DataFrame(X_pca_2, columns=['PC1', 'PC2'])
df_pca['diagnosis'] = y
```


Gambar 1.12

Penjelasan:

Hasil transformasi PCA disimpan ke dalam DataFrame agar mudah dianalisis dan divisualisasikan.

```
plt.figure()
plt.scatter(
    df_pca[df_pca['diagnosis'] == 0]['PC1'],
    df_pca[df_pca['diagnosis'] == 0]['PC2'],
    label='Benign'
)
plt.scatter(
    df_pca[df_pca['diagnosis'] == 1]['PC1'],
    df_pca[df_pca['diagnosis'] == 1]['PC2'],
    label='Malignant'
)

plt.xlabel('Principal Component 1')
plt.ylabel('Principal Component 2')
plt.legend()
plt.title('PCA pada Dataset Kanker Payudara')
plt.show()
```



Gambar 1.13

Penjelasan:

Visualisasi ini menunjukkan bahwa:

1. Data Benign dan Malignant cukup terpisah
2. PCA mampu merangkum 30 fitur menjadi 2 dimensi yang informatif

```
print(pca_2.explained_variance_ratio_)
print("Total Variance:", sum(pca_2.explained_variance_ratio_))

[0.44272026 0.18971182]
Total Variance: 0.6324320765155944
```

Gambar 1.14

Penjelasan:

Kode ini digunakan untuk mengetahui:

1. Kontribusi masing-masing komponen
2. Total variance yang dipertahankan oleh 2 komponen utama

total variance mencapai sekitar 63%.

Link github praktikum:

https://github.com/MuhZaidanRamdhan/machine-learning/blob/main/pertemuan12/praktikum_12/notebooks/praktikum_12.ipynb

Link github tugas:

https://github.com/MuhZaidanRamdhan/machine-learning/blob/main/pertemuan12/praktikum_mandiri/notebooks/praktikum_mandiri.ipynb